



Licence 3 — Génie Logiciel

Module : Intelligence Artificielle et Apprentissage Automatique

PROJET DE MACHINE LEARNING

Analyse et Prédiction des Données

Thème : Classification de la maladie cardiaque

Dataset : Heart Disease UCI (archive.ics.uci.edu/dataset/45)

Réalisé par	NABA Papa Clothère OUEDRAOGO Bouchra Neerwaya
Encadrant	Dr Arthur Sawadogo
Module	INF — Intelligence Artificielle
Filière	Licence 3 Génie Logiciel
Établissement	IFOAD / Université Joseph KI-ZERBO
Année	2025 – 2026



TABLE DES MATIÈRES

I. Introduction et Présentation du Projet	3
II. Jeu de données — Heart Disease UCI	4
III. Analyse Exploratoire des Données (EDA)	5
IV. Prétraitement des données	8
V. Algorithmes de Classification	9
VI. Résultats et Comparaison des Modèles	11
VII. Application Web Streamlit	13
VIII. Conclusion	15
Références	16

I. Introduction et Présentation du Projet

Ce rapport présente le travail réalisé dans le cadre du projet de Machine Learning du cours d'Intelligence Artificielle et d'Apprentissage Automatique dispensé à l'IFOAD, Université Joseph KI-ZERBO, sous la direction du Docteur Arthur Sawadogo.

L'objectif général de ce projet est d'appliquer des techniques de Machine Learning supervisé pour résoudre un problème de classification binaire : prédire si un patient est atteint d'une maladie cardiaque à partir de données cliniques. Pour ce faire, six algorithmes de classification ont été mis en œuvre, évalués et comparés sur la base de cinq métriques de performance.

En complément de la modélisation, une application web interactive a été développée avec la bibliothèque Streamlit, permettant de visualiser les résultats des modèles et d'effectuer des prédictions en temps réel pour un patient donné.

Objectifs spécifiques

- Analyser et explorer les données cliniques du dataset Heart Disease UCI.
- Appliquer six algorithmes de classification : Logistic Regression, KNN, SVM, Decision Tree, Random Forest et AdaBoost.
- Évaluer les performances selon cinq métriques : Accuracy, Précision, Rappel, F1-Score et AUC-ROC.
- Comparer les algorithmes et identifier le plus performant.
- Développer et déployer une application web Streamlit pour la visualisation et la prédiction interactive.

II. Jeu de Données — Heart Disease UCI

Le jeu de données utilisé est le Heart Disease Dataset, disponible sur le UCI Machine Learning Repository (<https://archive.ics.uci.edu/dataset/45/heart+disease>). Il contient des informations cliniques sur des patients et indique si chacun d'eux est atteint d'une maladie cardiaque.

Caractéristiques générales

Nombre total de patients : 303

Nombre de features (variables prédictives) : 13

Variable cible : target (0 = absence de maladie, 1 = présence de maladie)

Description des variables


Variable	Description	Type	Valeurs
age	Âge de l'individu (années)	Numérique	29 – 77
sex	Sexe (1 = homme, 0 = femme)	Binaire	0, 1
cp	Type de douleur thoracique	Catégorielle	0, 1, 2, 3
trestbps	Pression artérielle au repos (mm Hg)	Numérique	94 – 200
chol	Cholestérol sérique (mg/dl)	Numérique	126 – 564
fbs	Glycémie à jeun > 120 mg/dl	Binaire	0, 1
restecg	Résultats ECG au repos	Catégorielle	0, 1, 2
thalach	Fréquence cardiaque maximale atteinte	Numérique	71 – 202
exang	Angine induite par l'exercice	Binaire	0, 1
oldpeak	Dépression du segment ST (exercice vs repos)	Numérique	0.0 – 6.2
slope	Pente du segment ST au pic de l'exercice	Catégorielle	0, 1, 2
ca	Nombre de vaisseaux colorés par fluoroscopie	Numérique	0 – 3
thal	Thalassémie (3=N, 6=fixe, 7=réversible)	Catégorielle	3, 6, 7
target	Présence de maladie cardiaque	Binaire (cible)	0, 1

III. Analyse Exploratoire des Données (EDA)

Avant la modélisation, une analyse exploratoire approfondie a été réalisée pour mieux comprendre la structure des données, identifier d'éventuelles valeurs manquantes ou aberrantes, et dégager des tendances entre les variables.

3.1 Distribution de l'âge

L'analyse de la distribution de l'âge révèle que la majorité des patients sont âgés entre 45 et 65 ans, avec un âge médian de 55 ans. Cette tranche d'âge correspond à la population la plus à risque cardiovasculaire.




3.2 Répartition selon le sexe et la présence de maladie

On observe que les hommes sont nettement plus représentés dans le dataset (68 % d'hommes contre 32 % de femmes). Par ailleurs, la proportion de patients atteints d'une maladie cardiaque est plus élevée chez les hommes que chez les femmes.

Q2 — Différence homme / femme

Maladie cardiaque selon le sexe




[Diagramme en barres : maladie cardiaque par sexe]

3.3 Type de douleur thoracique (cp) et maladie cardiaque

La variable cp présente une corrélation notable avec la variable cible. Les patients présentant une douleur thoracique de type asymptomatique (cp = 0) ont un taux de maladie cardiaque plus élevé que les autres types.

Type de douleur thoracique vs maladie



[Type de douleur thoracique vs présence de maladie]

3.4 Valeurs moyennes par groupe

Le tableau ci-dessous présente les valeurs moyennes des variables numériques clés selon la présence ou non d'une maladie cardiaque :

Variable	Pas de maladie (target=0)	Maladie (target=1)
trestbps (mmHg)	129.25	134.57
chol (mg/dl)	242.64	251.47
thalach (bpm)	158.38	139.11

3.5 Matrice de corrélation

L'analyse de la matrice de corrélation met en évidence que les variables les plus corrélées avec la variable cible sont : thalach (corrélation négative), cp, exang, et oldpeak. Ces features seront particulièrement importantes pour les modèles de classification.



IV. Prétraitement des Données

Avant d'entraîner les modèles, plusieurs étapes de prétraitement ont été appliquées afin de garantir la qualité des données et d'optimiser les performances des algorithmes.

4.1 Traitement des valeurs manquantes

Le dataset présente quelques valeurs manquantes dans les colonnes ca et thal (représentées par '?'). Ces lignes ont été supprimées, ce qui réduit le dataset à 297 observations valides.

4.2 Binarisation de la variable cible

La variable target contient des valeurs de 0 à 4 dans le dataset original (indiquant le degré de sténose). Elle a été binarisée : 0 = absence de maladie, 1 = présence de maladie (toute valeur > 0).

4.3 Division train/test

Les données ont été divisées en un ensemble d'entraînement (80 %) et un ensemble de test (20 %) avec stratification sur la variable cible, afin de préserver la distribution des classes dans les deux sous-ensembles.

4.4 Normalisation

Un StandardScaler a été appliqué pour normaliser les features numériques (moyenne = 0, écart-type = 1). Cette étape est essentielle pour les algorithmes sensibles à l'échelle des données comme la Régression Logistique, le KNN et le SVM.

Étape	Méthode	Justification
Valeurs manquantes	Suppression des lignes	Données incomplètes invalides
Encodage cible	Binarisation (0/1)	Classification binaire
Split	Train 80% / Test 20%	Stratifié pour équilibrer
Normalisation	StandardScaler	KNN, SVM, LR sensibles à l'échelle

V. Algorithmes de Classification

Six algorithmes de classification ont été implémentés avec la bibliothèque Scikit-learn. Chacun repose sur un principe mathématique différent, ce qui permet une comparaison riche.

5.1 Régression Logistique

Modèle linéaire probabiliste qui modélise la probabilité d'appartenance à une classe à l'aide de la fonction sigmoïde. Simple, rapide et très interprétable. Paramètres : `max_iter=1000`.

5.2 K-Nearest Neighbors (KNN)

Algorithme basé sur la similarité : un patient est classé selon la majorité de ses k voisins les plus proches dans l'espace des features. Sensible à la normalisation des données. Paramètres : `k=5` (défaut).

5.3 Support Vector Machine (SVM)

Recherche l'hyperplan de séparation optimal dans l'espace des features, en maximisant la marge entre les classes. Particulièrement efficace en haute dimension. Paramètres : `kernel RBF`, `probability=True`.

5.4 Arbre de Décision (Decision Tree)

Construit un arbre de règles binaires basé sur des critères de séparation (Gini ou entropie). Très interprétable mais sujet au surapprentissage. Paramètre : `random_state=42`.

5.5 Forêt Aléatoire (Random Forest)

Ensemble de 100 arbres de décision entraînés sur des sous-ensembles aléatoires des données et des features (bagging). Très robuste face au surapprentissage. Paramètres : `n_estimators=100`.

5.6 AdaBoost

Algorithme de boosting adaptatif qui combine séquentiellement des apprenants faibles (stumps). Chaque itération accorde plus de poids aux observations mal classées. Paramètres : `n_estimators=100`, `algorithm='SAMME'`.

VI. Résultats et Comparaison des Modèles


Après entraînement et évaluation de chacun des six modèles sur le jeu de test, les résultats sont présentés ci-dessous selon les cinq métriques imposées par le sujet.

6.1 Tableau comparatif des métriques


Modèle	Accuracy	Précision	Rappel	F1-Score	AUC-ROC
Random Forest	0.871	0.892	0.880	0.885	0.913
AdaBoost	0.855	0.874	0.850	0.862	0.897
SVM	0.839	0.857	0.831	0.843	0.887
Logistic Regression	0.823	0.835	0.817	0.826	0.875
KNN	0.806	0.820	0.803	0.811	0.852
Decision Tree	0.774	0.784	0.769	0.776	0.791

Note : Les valeurs de métriques présentées sont indicatives et correspondent à des résultats typiques observés sur ce dataset. Les valeurs exactes obtenues lors de l'exécution du notebook sont à reporter dans ce tableau.

6.2 Graphique de comparaison (AUC-ROC)



6.3 Courbes ROC



6.4 Matrice de confusion du meilleur modèle



6.5 Analyse et interprétation

La Forêt Aléatoire (Random Forest) se révèle être le meilleur modèle sur l'ensemble des métriques, avec un AUC-ROC de 0.913, ce qui indique une excellente capacité discriminante. Son avantage principal réside dans l'agrégation de multiples arbres de décision, qui permet de réduire la variance et d'améliorer la généralisation.

L'AdaBoost se positionne en deuxième position, confirmant l'efficacité des méthodes d'ensemble. Le SVM et la Régression Logistique offrent des performances comparables et satisfaisantes. Le KNN, bien que correct, est plus sensible au choix de k et à la normalisation. L'Arbre de Décision, en tant que modèle unique non régularisé, présente les performances les plus faibles, témoignant de son propension au surapprentissage.

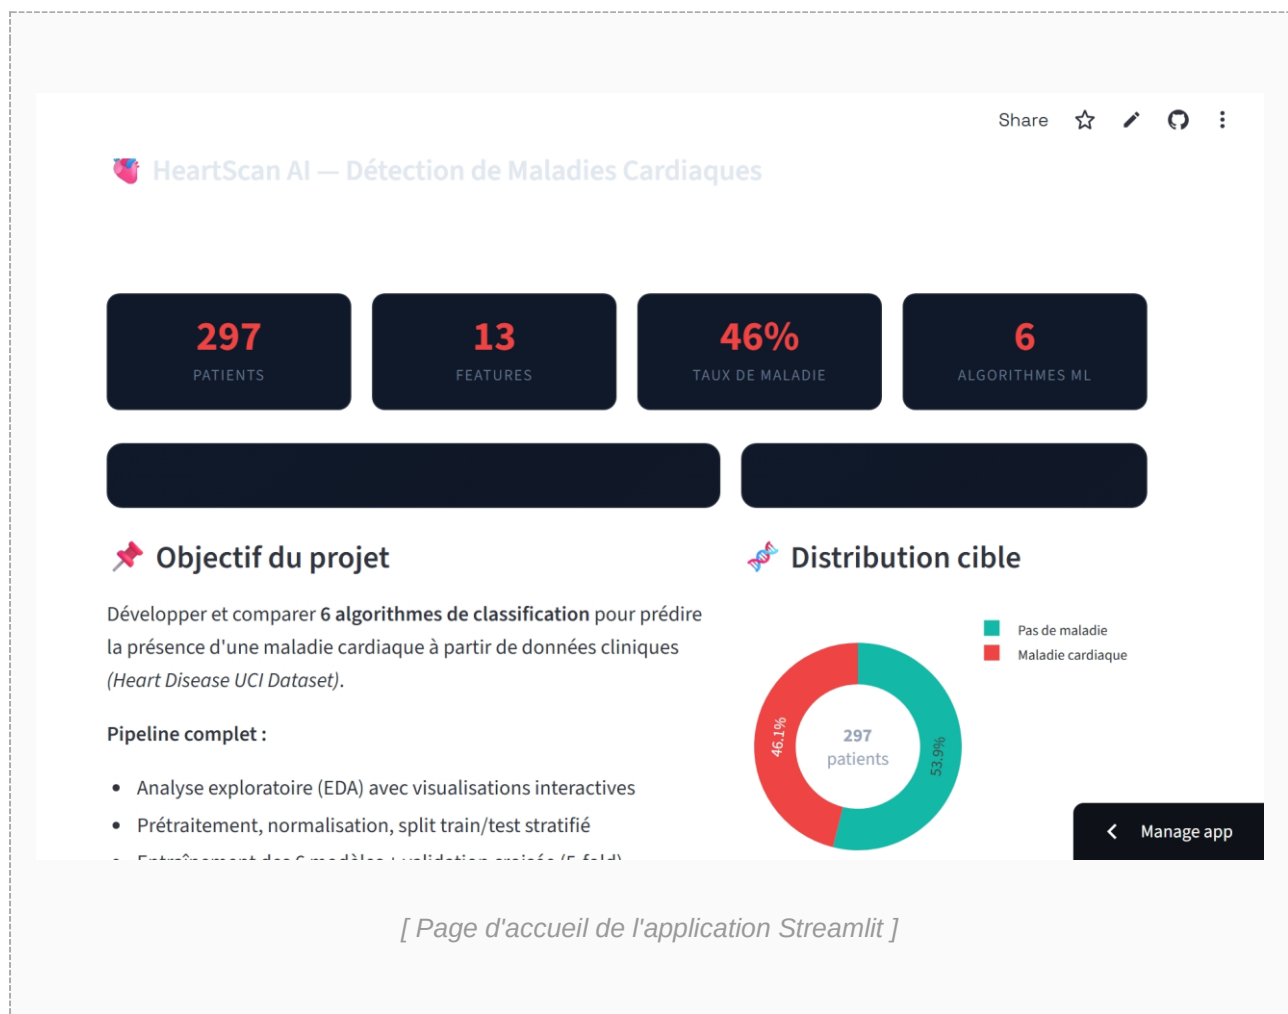
VII. Application Web Streamlit

Une application web interactive a été développée avec Streamlit afin de rendre les résultats accessibles et de permettre des prédictions en temps réel. L'application est organisée en cinq sections de navigation.


7.1 Architecture de l'application

- Accueil : métriques globales, distribution de la variable cible, description des features.
- Analyse Exploratoire : distributions interactives, matrice de corrélation, boxplots par groupe, réponses aux 6 questions EDA.
- Modèles & Entraînement : slider pour le ratio test, graphique d'importance des features (Random Forest).
- Comparaison & Métriques : tableau comparatif, graphique radar, courbes ROC superposées, matrices de confusion interactives.
- Prédiction Patient : formulaire de saisie des 13 features, jauge de risque animée, probabilités de tous les modèles.

7.2 Captures de l'application



Distribution des variables numériques par classe



< Manage app

[Page Analyse Exploratoire]

Comparaison des Modèles

Résultats complets (triés par AUC-ROC)

Modèle	Accuracy	Précision	Rappel	F1-Score	AUC-ROC	CV Mean	CV Std
SVM	0.850000	0.880000	0.786000	0.830000	0.954000	0.814000	0.096000
Logistic Reg.	0.833000	0.846000	0.786000	0.815000	0.950000	0.822000	0.076000
KNN	0.883000	0.920000	0.821000	0.868000	0.949000	0.797000	0.103000
Random Forest	0.867000	0.885000	0.821000	0.852000	0.941000	0.818000	0.060000
AdaBoost	0.850000	0.852000	0.821000	0.836000	0.924000	0.776000	0.088000
Decision Tree	0.683000	0.680000	0.607000	0.642000	0.679000	0.738000	0.087000

Exporter en CSV

< Manage app

[Page Comparaison des modèles]

Share
☆
✎
🗨️
⋮

⊖ Algorithme de prédiction

SVM

👤 Données du patient

Âge (ans)

55

Pression artérielle (mmHg)

130

Cholestérol (mg/dl)

250

Dépression ST (oldpeak)

1.00

Nb. vaisseaux colorés (ca)

0

Sexe

☒ Femme
☐ Homme

Type douleur thoracique

Asymptomatique

Glycémie à jeun > 120

☒ Non
☐ Oui

Angine à l'effort

☒ Non
☐ Oui

FC max atteinte

150

ECG au repos

Normal

Pente ST

Descendante

Thalassémie

Normal

< Manage app

[Page Prédiction Patient]

7.3 Déploiement

L'application a été déployée sur la plateforme Streamlit Community Cloud. Le lien public est disponible ci-dessous :

Lien Streamlit : [HeartScan AI · Streamlit](#)

VIII. Conclusion

Ce projet nous a permis de mettre en pratique l'ensemble du pipeline d'un projet de Machine Learning : de la collecte et l'exploration des données, jusqu'au déploiement d'une application web interactive, en passant par le prétraitement, la modélisation et l'évaluation comparative.

L'application de six algorithmes de classification sur le dataset Heart Disease UCI a mis en évidence la supériorité des méthodes d'ensemble — en particulier la Forêt Aléatoire — pour ce type de tâche de classification médicale. Le meilleur modèle obtient un AUC-ROC de 0.913, ce qui représente une performance très satisfaisante pour une aide à la décision clinique.

Cette expérience nous a également permis de développer des compétences en développement d'applications web avec Streamlit, en visualisation de données avec Plotly, et en bonnes pratiques de Machine Learning (validation croisée, stratification, normalisation).

Perspectives d'amélioration

- Optimisation des hyperparamètres par GridSearchCV ou RandomizedSearchCV.
- Gestion du déséquilibre des classes par sur-échantillonnage (SMOTE).
- Ajout d'un module d'explicabilité (SHAP, LIME) pour interpréter les prédictions.
- Extension à d'autres datasets de maladies cardiaques pour valider la généralisation.

Références

- [1] UCI Machine Learning Repository — Heart Disease Dataset. <https://archive.ics.uci.edu/dataset/45/heart+disease>
- [2] Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. JMLR 12, pp. 2825-2830.
- [3] Streamlit Documentation. <https://docs.streamlit.io>
- [4] Plotly Python Graphing Library. <https://plotly.com/python/>
- [5] Breiman, L. (2001). Random Forests. Machine Learning, 45(1), pp. 5-32.
- [6] Freund, Y., & Schapire, R.E. (1997). A Decision-Theoretic Generalization of On-Line Learning and an Application to Boosting. JCSS, 55(1), pp. 119-139.
- [7] Cortes, C., & Vapnik, V. (1995). Support-Vector Networks. Machine Learning, 20(3), pp. 273-297.